

HADOOP - RETOS AVANZADOS

MANEJO MASIVO DE DATOS

IDIA 224 UPQ

¿QUÉ ES HADOOP?

PROPOSITO DE HADOOP

Hadoop es un framework de codigo abierto que esta diseñado para almacenar y procesar grandes volumenes masivos de datos (Big Data) de forma distribuida en clusters de computadoras.

En otras palabras, en lugar de requerir una sola supercomputadora para leer un archivo gigante. Hadoop divide los datos en bloques y los procesa en paralelo entre muchas maquinas.

Sus tres componentes principales son:

- **HDFS** (Sistema de archivo distribuido)
- **YARN** (Gestor de recursos del cluster)
- **MapReduce** (Modelo de programacion que divide las tareas en dos fases. MAP para filtrar y transformar y Reduce para agrupar y resumer los resultados)



COMPARATIVA RAPIDA



DEFINICIONES:

WORDCOUNT: es un programa de hadoop sumamente útil para manejo de grandes volumenes de datos. La función del WORDCOUNT es el llevar un conteo de frecuencia en el que una palabra se repite en una conjunto de datos masivo

GREP: este programa tiene la función de buscar e identificar patrones o expreciones regulares en grandes volumenes de datos

¿QUÉ HACE?

SECONDARYSORT

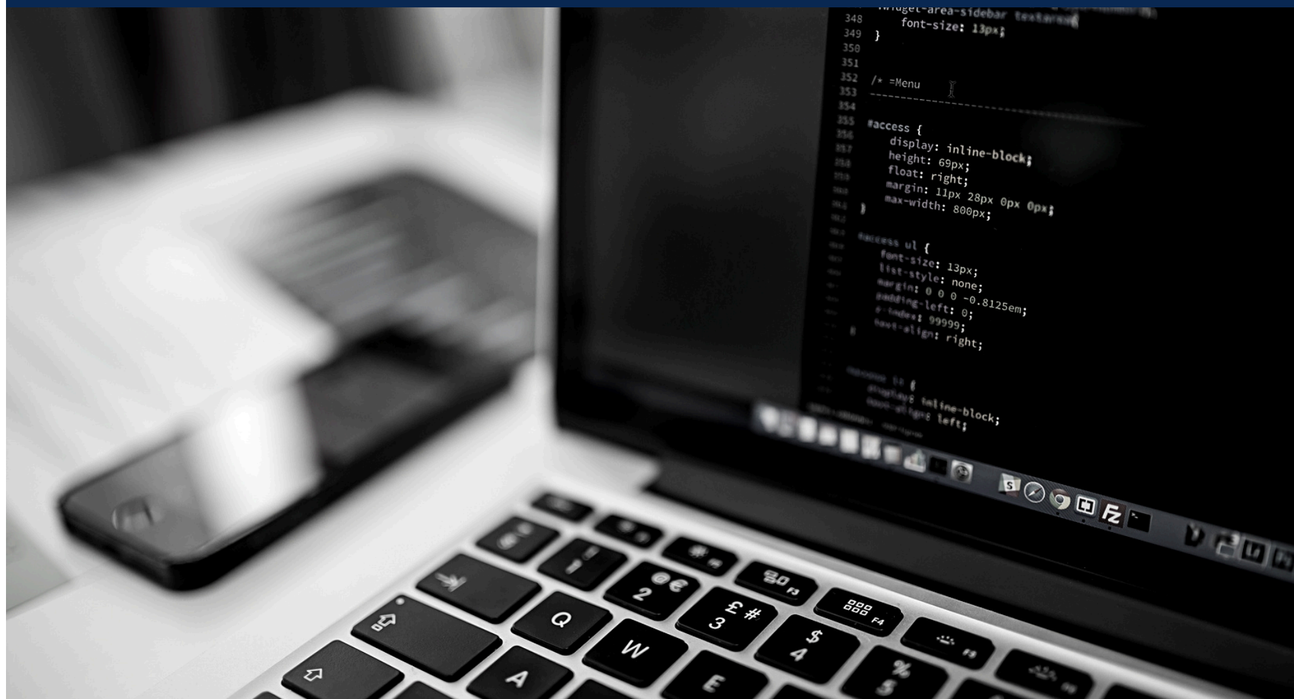
Por defecto, la dase de *Shuffle y Sort* de Hadoop ordena los datos unicamente por la primera columna (Key), pero los valores asociados a esa clave llegan al Reducer en un orden aleatorio.

Secondarysort lo que hace es modifica el particionador y el comparador para ordenar por la primera columna y, en caso de empate, ordenar tambien por la segunda columna.

Caso de la vida Real
El secondarysort se puede usar en muchos ambitos, especialmente en la industria. Por ejemplo, en sensores meteorológicos.

Normalmente en estos sensores hay registros como Año y temperatura, y si tu deseas agrupar por año, el secondarysort seria especialmente importante para hacer que las lecturas lleguen al Reducer ordenadas cronologicamente o en otro caso, de menor a mayor temperatura.

"LAS TÉCNICAS AVANZADAS SON UN SALTO HACIA EL FUTURO"



CASO 2



JOIN

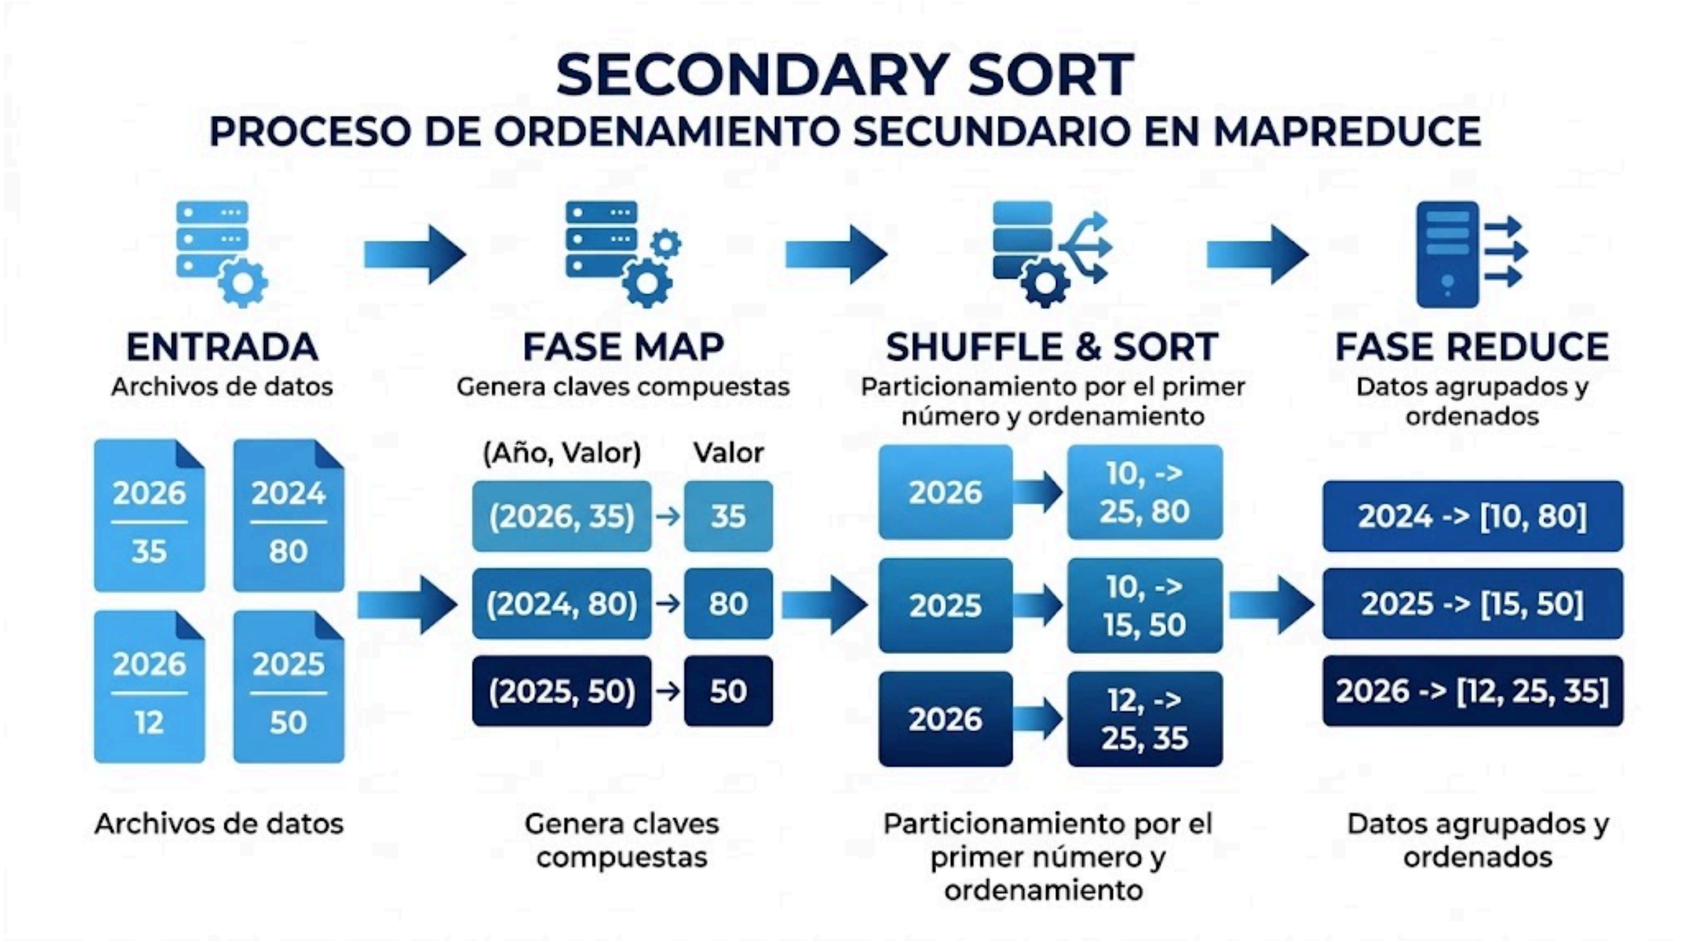
En este otro caso, *JOIN* hace una accion parecida a *INNER JOIN o OUTER JOIN* de SQL. En otras palabras, realiza un cruce relacional entre dos o más archivos grandes que comparten una misma clave.

Caso de Vida Real

El JOIN puede ser especialmente util como cuando se requiere cruzar en un e-commerce un archivo gigante de Cliente contra otro archivo de Compras para saber cuanto compro cada persona.

DIAGRAMA

DIAGRAMA


SECONDARY SORT
PROCESO DE ORDENAMIENTO SECUNDARIO EN MAPREDUCE
ENTRADA
Archivos de datos
FASE MAP
Genera claves compuestas
SHUFFLE & SORT
Particionamiento por el primer número y ordenamiento
FASE REDUCE
Datos agrupados y ordenados
2026
35
2024
80
2026
12
2025
50
(Año, Valor)
Valor
(2026, 35)
35
(2024, 80)
80
(2025, 50)
50
2026
10, -> 25, 80
2025
10, -> 15, 50
2026
12, -> 25, 35
2024 -> [10, 80]
2025 -> [15, 50]
2026 -> [12, 25, 35]
Archivos de datos
Genera claves compuestas
Particionamiento por el primer número y ordenamiento
Datos agrupados y ordenados

BONUS

DBCOUNT

En este caso, *dbcount* es un ejemplo que conecta MapReduce directamente a una base de datos relacional SQL via JDBC (usando DBInputFormat y DBOutputFormat) en lugar de leer archivos de texto.

Simula un contador de visitas a paginas web leyendo los registros de una tabla Access y escribiendo la suma total en otra tabla.

En este caso, requiere tener un motor de base de datos relacional levantando y un driver JDBC en el classpath de Hadoop.

Actualmente se suele usar Apache Sqoop o Spark JDBC para esto.

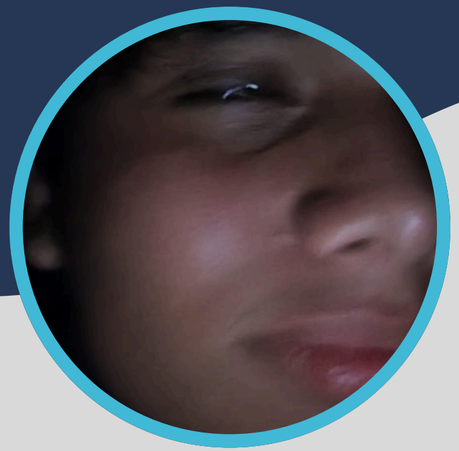
Se suele usar en tiendas en linea tipo Amazon o Mercado Lubre para registrar el total de visitas o clics a un producto.



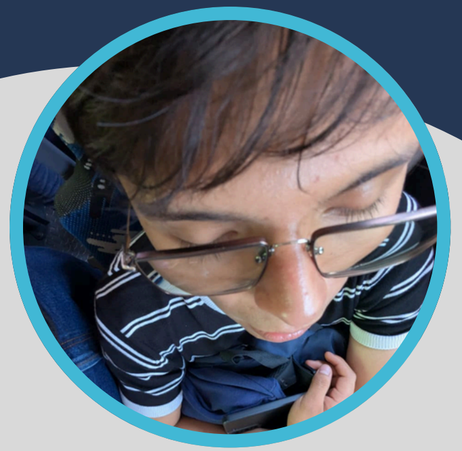
EL EQUIPO



Josue Sifuentes
Simplemente Josue



Daniel Croche
Apostador en Exc.



Felipe Gonzalez
Telera 🥖



Marco Galicia
Marco God

MUCHAS GRACIAS

MANEJO MASIVO DE DATOS

IDIA 224 UPQ